

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	2
1 Анализ профессиональной информации по индивидуальной теме	3
1.1 Постановка задачи	3
1.2 Поиск и анализ профессиональной информации	5
1.3 Результаты исследования	7
1.3.1 Принцип работы CNN	7
1.3.2 Основные архитектуры CNN	8
1.3.3 Области практического применения CNN	12
1.3.4 Сравнительный анализ применения CNN	16
1.3.5 Современные тенденции развития CNN	18
1.4 Выводы и рекомендации	20
ЗАКЛЮЧЕНИЕ	24
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	25

ВВЕДЕНИЕ

Целью учебной (аналитической) практики являлось приобретение и закрепление практических навыков в двух направлениях: (1) поиск, изучение и систематизация профессиональной информации по индивидуальной теме исследования и (2) практическая работа со средствами операционных систем в рамках мероприятий компании-партнёра. Индивидуальным заданием на практику была определена тема «Анализ сверточных нейронных сетей и областей их практического применения».

Задачи практики, соответствующие индивидуальной теме, состояли в следующем: изучить принцип работы сверточных нейронных сетей (CNN); найти и критически проанализировать профессиональную литературу, посвящённую основным архитектурам CNN и областям их практического применения; провести сравнительный анализ архитектур и областей применения по единым критериям; сформулировать обоснованные выводы и практические рекомендации по выбору архитектуры CNN в зависимости от решаемой задачи.

Актуальность темы обусловлена тем, что сверточные нейронные сети на протяжении последнего десятилетия остаются базовой технологией компьютерного зрения и лежат в основе большинства промышленных систем классификации изображений, обнаружения объектов, сегментации, а также специализированных приложений — от медицинской диагностики до автономного транспорта. Одновременно с ростом точности моделей возрастают и требования к вычислительным ресурсам, что делает задачу обоснованного выбора архитектуры под конкретные условия эксплуатации практически значимой как для исследователей, так и для инженеров, внедряющих подобные системы.

В рамках практической части был получен опыт работы с операционной системой Linux; результаты этой части будут оформлены отдельно и не входят в текущий этап работы над отчётом.

Структура настоящего этапа отчёта соответствует индивидуальному заданию и включает анализ профессиональной информации по индивидуальной теме (раздел 1), заключение и список использованных источников.

1 АНАЛИЗ ПРОФЕССИОНАЛЬНОЙ ИНФОРМАЦИИ ПО ИНДИВИДУАЛЬНОЙ ТЕМЕ

1.1 Постановка задачи

Индивидуальной темой практики является «Анализ сверточных нейронных сетей и областей их практического применения». Сверточные нейронные сети (англ. **convolutional neural networks**, CNN) представляют собой класс архитектур глубокого обучения, специально приспособленных для обработки данных с выраженной пространственной структурой — прежде всего изображений и видео. В отличие от полносвязных нейронных сетей, CNN используют операцию свёртки с общими (разделяемыми) весами и локальные рецептивные поля, что позволяет резко сократить число обучаемых параметров и одновременно обеспечить частичную инвариантность к сдвигу, масштабу и другим пространственным искажениям входных данных [1, 2].

Актуальность исследования определяется тем, что за последнее десятилетие CNN стали фактическим стандартом решения задач компьютерного зрения и легли в основу промышленных систем в самых разных отраслях — от медицинской диагностики до автономного транспорта и промышленного контроля качества. При этом семейство архитектур CNN крайне неоднородно: одни модели (VGG, ResNet, DenseNet) ориентированы на максимальную точность и применяются на серверных GPU-кластерах, другие (MobileNet, EfficientNet) специально спроектированы для мобильных и встраиваемых устройств с жёсткими ограничениями по памяти и энергопотреблению. Обоснованный выбор архитектуры под конкретную практическую задачу требует систематического сравнения этих решений, что и составляет содержательное ядро данной работы.

Цель исследования — на основании анализа профессиональной литературы систематизировать сведения об основных архитектурах сверточных нейронных сетей и провести сравнительный анализ областей их практического применения для формирования обоснованных рекомендаций по выбору архитектуры в зависимости от решаемой задачи.

Для достижения поставленной цели необходимо решить следующие **задачи исследования**:

1. Раскрыть принцип работы сверточной нейронной сети: структуру, операцию свёртки, функции активации, слои подвыборки (pooling), полносвязные слои, процесс обучения и методы регуляризации.
2. Изучить и систематизировать сведения об основных архитектурах CNN (LeNet, AlexNet, VGG, GoogLeNet/Inception, ResNet, DenseNet, MobileNet, EfficientNet) и провести их сравнительный анализ по единым критериям.
3. Рассмотреть области практического применения CNN (классификация изображений, обнаружение объектов, сегментация, медицинская диагностика, автономный транспорт, робототехника, видеонаблюдение, распознавание лиц, промышленный контроль качества, анализ спутниковых изображений, обработка видео, OCR) и для каждой из них определить решаемую задачу, используемые данные, применимые архитектуры, преимущества и ограничения.
4. Провести сравнительный анализ областей применения CNN и современных тенденций развития технологии (лёгкие архитектуры, edge AI, pruning, quantization, knowledge distillation, transfer learning).
5. Сформулировать выводы и практические рекомендации по выбору архитектуры CNN в зависимости от вычислительных ограничений, требований к точности и специфики предметной области.

Объектом исследования являются сверточные нейронные сети как класс архитектур глубокого обучения. **Предметом** исследования — сравнительные характеристики архитектур CNN и особенности их применения в различных прикладных областях.

В качестве **критериев сравнения** архитектур и областей применения приняты: год появления архитектуры и её ключевая идея; глубина сети и порядок числа параметров (там, где эти сведения подтверждены источниками); вычислительная сложность и требования к памяти; достигнутая точность на общепринятых тестовых наборах данных (при наличии подтверждённых данных); применимость для устройств с ограниченными ресурсами; типичные области использования; основные преимущества и недостатки архитектуры.

1.2 Поиск и анализ профессиональной информации

Поиск профессиональной информации проводился по следующим направлениям: (а) оригинальные публикации, в которых были впервые предложены основные архитектуры CNN; (б) обзорные (survey/review) статьи, обобщающие развитие архитектур CNN и результаты их применения в конкретных предметных областях; (в) публикации, посвящённые методам оптимизации и сжатия моделей CNN для развёртывания на устройствах с ограниченными ресурсами.

Поиск осуществлялся по научным базам и агрегаторам (arXiv, IEEE Xplore, Scopus/Web of Science, elibrary.ru) по запросам вида «convolutional neural network architecture comparison», «CNN medical image analysis review», «object detection deep learning survey», «model compression neural networks survey», «autonomous driving deep learning survey», «сверточные нейронные сети применение». Отбор источников производился по следующим критериям: рецензируемость издания (журнальная статья или статья в трудах ведущей конференции по компьютерному зрению — CVPR, ICLR, ICML — либо издание, индексируемое Scopus/Web of Science/РИНЦ); проверяемость выходных данных (наличие DOI или иного устойчивого идентификатора); соответствие содержания заявленным разделам индивидуального задания.

Большинство отобранных источников — обзорные статьи 2020–2025 гг., что соответствует требованию к актуальности используемой литературы. Исключение сделано для восьми оригинальных публикаций, в которых были впервые предложены рассматриваемые в разделе 1.3.2 архитектуры (LeNet, AlexNet, VGG, GoogLeNet, ResNet, DenseNet, MobileNet, EfficientNet): без обращения к этим работам корректно раскрыть историю и техническую суть архитектур невозможно, поскольку именно в них впервые вводятся ключевые идеи (остаточные связи, плотные соединения, разделяемые по глубине свёртки и т. д.), на которые ссылаются все более поздние обзоры. Это соответствует прямо оговорённому в задании исключению для «фундаментальных работ, без которых невозможно корректно объяснить развитие CNN».

Наиболее авторитетными и полезными для целей исследования оказались комплексный обзор Alzubaidi et al. [1], охватывающий развитие архитектур CNN от AlexNet до сетей с высоким разрешением признаков карт и систематизирующий области их применения, а также специализированные обзоры по отдельным предметным областям — медицинской визуализации [3], обнаружению объектов [4], автономному вождению [5] и сжатию моделей [6, 7]. Эти работы предпочтительнее отдельных экспериментальных статей именно потому, что они обобщают результаты десятков и сотен первичных исследований и позволяют увидеть общие закономерности, а не результат одного эксперимента на одном наборе данных.

Сопоставление источников показывает, что позиции авторов в целом согласуются в отношении общей траектории развития архитектур CNN — от неглубоких сетей (LeNet, AlexNet) к очень глубоким (VGG, ResNet, DenseNet) и далее к архитектурам, оптимизированным по соотношению «точность/вычислительные затраты» (MobileNet, EfficientNet) [1]. Вместе с тем в литературе нет единого мнения о том, какая архитектура является «оптимальной»: выбор существенно зависит от предметной области и аппаратных ограничений, что отдельно подчёркивается в обзорах по автономному вождению [5] и медицинской визуализации [3], где авторы отмечают, что более глубокие и точные модели не всегда пригодны для развёртывания в реальном времени на ограниченном по ресурсам оборудовании. Данное наблюдение стало одним из отправных пунктов сравнительного анализа, проведённого в разделе 1.3.4.

Направления развития CNN, прослеживающиеся в современной литературе, включают: рост внимания к лёгким («mobile-friendly») архитектурам и методам сжатия моделей — pruning, квантование, дистилляция знаний [6, 7] перенос обучения (transfer learning) как способ снижения требований к объёму размеченных данных, особенно в медицинской визуализации [3] комбинирование CNN с механизмами внимания и архитектурами-трансформерами в задачах обнаружения объектов [4] а также растущий интерес к развёртыванию CNN на специализированных встраиваемых платформах непосредственно на объекте (edge AI), в том числе в системах промышленного контроля качества и автономных транспортных средствах [5, 8].

1.3 Результаты исследования

1.3.1 Принцип работы CNN

Сверточная нейронная сеть представляет собой последовательность слоёв, каждый из которых преобразует входной массив данных (тензор) в новый признаковый тензор. Типовая структура CNN, предложенная ещё в архитектуре LeNet [2], включает чередование сверточных слоёв, слоёв подвыборки (pooling) и завершающих полносвязных слоёв с функцией softmax на выходе [1, 2].

Операция свёртки и карты признаков. Сверточный слой выполняет скользящее по пространственным координатам изображения поэлементное умножение фрагмента входного тензора на матрицу весов (ядро свёртки, фильтр) с последующим суммированием произведений и добавлением смещения (bias). Результатом применения одного фильтра ко всему изображению является карта признаков (feature map), на которой высокие значения соответствуют участкам изображения, наиболее похожим на паттерн, который «умеет» находить данный фильтр. Поскольку один и тот же фильтр применяется ко всем участкам изображения (разделяемые веса), число обучаемых параметров сверточного слоя не зависит от размера входного изображения и оказывается на порядки меньше, чем в полносвязном слое аналогичной «широты» — именно это архитектурное решение и легло в основу масштабируемости CNN [1]. Как правило, в одном слое используется набор из нескольких десятков–сотен различных фильтров, что позволяет одновременно выделять множество разнородных признаков — от простых границ и перепадов яркости в первых слоях до сложных, семантически содержательных паттернов в глубоких слоях сети.

Функции активации. После свёртки к результату применяется нелинейная функция активации. Начиная с архитектуры AlexNet [9] стандартом де-факто стала функция ReLU (rectified linear unit, $f(x) = \max(0, x)$), которая, в отличие от сигмоиды и гиперболического тангенса, не насыщается при положительных значениях аргумента и позволяет существенно ускорить обучение глубоких сетей.

Слои подвыборки (pooling). Слои подвыборки уменьшают пространственную размерность карт признаков, обобщая значения в пределах

локальной окрестности (чаще всего — выбором максимума, max-pooling). Это снижает вычислительную нагрузку в последующих слоях, увеличивает эффективное рецептивное поле нейронов и повышает устойчивость сети к небольшим сдвигам и искажениям входного изображения.

Полносвязные слои и функция потерь. Завершающие слои классической CNN — один или несколько полносвязных слоёв, преобразующих признаки, извлечённые сверточной частью сети, в итоговый вектор вероятностей классов (как правило, через функцию softmax). Обучение сети производится путём минимизации функции потерь (чаще всего — категориальной кросс-энтропии для задач классификации) с использованием алгоритма обратного распространения ошибки (backpropagation): градиент функции потерь последовательно распространяется от выходного слоя ко входному, а параметры сети обновляются одним из вариантов стохастического градиентного спуска.

Переобучение и регуляризация. Из-за большого числа параметров глубокие CNN подвержены переобучению — ситуации, при которой сеть запоминает обучающую выборку, но плохо обобщается на новые данные. Для борьбы с переобучением применяются: регуляризация весов (L1/L2), исключение случайных нейронов на этапе обучения (dropout, впервые применённый в AlexNet [9]), нормализация по мини-батчам (batch normalization, использованная, в частности, в ResNet [12]), а также искусственное расширение обучающей выборки (аугментация данных) и перенос обучения с предварительно обученных моделей [1, 3].

1.3.2 Основные архитектуры CNN

Развитие архитектур CNN на протяжении последних трёх десятилетий шло по пути постепенного увеличения глубины сети и одновременного поиска способов сделать обучение всё более глубоких сетей возможным и вычислительно эффективным, а начиная с середины 2010-х годов — также по пути специализированного проектирования лёгких архитектур для мобильных и встраиваемых устройств [1].

LeNet — одна из первых практически применённых сверточных архитектур, предложенная Я. ЛеКуном с соавторами для задачи распознавания рукописных цифр [2]. Сеть состоит из чередующихся сверточных слоёв и слоёв

подвыборки с последующими полносвязными слоями; несмотря на скромную по современным меркам глубину, именно в этой работе были заложены базовые принципы построения CNN, используемые во всех последующих архитектурах.

AlexNet [9] — архитектура, победившая в конкурсе ImageNet Large Scale Visual Recognition Challenge (ILSVRC) 2012 года с результатом top-5 ошибки 15,3 % против 26,2 % у второго места, что стало точкой отсчёта современной эпохи глубокого обучения в компьютерном зрении. Сеть состоит из пяти сверточных слоёв и трёх полносвязных слоёв, содержит порядка 60 млн обучаемых параметров и обучалась с использованием функции активации ReLU, dropout-регуляризации и распределённых вычислений на графических процессорах.

VGG [10] — семейство архитектур (VGG-11...VGG-19), исследовавшее эффект увеличения глубины сети при использовании исключительно малых свёрточных фильтров размером 3×3 . Сети VGG заняли первое и второе места в задачах локализации и классификации ILSVRC 2014 соответственно и продемонстрировали, что последовательное увеличение глубины до 16–19 весовых слоёв при простой, единообразной структуре само по себе даёт существенный прирост точности.

GoogLeNet / Inception [11] — архитектура глубиной 22 слоя, победившая в конкурсе ILSVRC 2014. Ключевая идея — модуль Inception, в котором свёртки разного размера (1×1 , 3×3 , 5×5) и операция подвыборки применяются параллельно и объединяются, что позволяет более эффективно использовать вычислительные ресурсы при увеличении глубины и ширины сети без пропорционального роста вычислительных затрат.

ResNet [12] — архитектура с остаточными связями (residual connections), при которых каждый блок обучается предсказывать не само выходное представление, а лишь остаточную поправку к входному сигналу. Такое решение устранило проблему затухания градиента при увеличении глубины сети и впервые сделало возможным устойчивое обучение сетей глубиной в десятки и сотни слоёв.

DenseNet [13] — развитие идеи остаточных связей, в котором каждый слой внутри плотного блока (dense block) получает на вход конкатенацию признаков карт всех предыдущих слоёв блока. Авторы показали, что при L

слоях такая схема образует $\frac{L(L+1)}{2}$ прямых связей вместо L связей в традиционной последовательной сети, что усиливает распространение признаков и градиента, поощряет их повторное использование и позволяет существенно сократить число параметров при сопоставимой или более высокой точности по сравнению с ResNet.

MobileNet [14] — семейство архитектур, специально спроектированных для мобильных и встраиваемых устройств. В основе лежит разделяемая по глубине свёртка (depthwise separable convolution), раскладывающая обычную свёртку на два более дешёвых по вычислениям этапа, а также два глобальных гиперпараметра, позволяющих разработчику напрямую регулировать баланс между задержкой (latency) и точностью модели под конкретные ограничения задачи.

EfficientNet [15] — семейство архитектур (EfficientNet-B0...B7), построенное на основе идеи составного масштабирования (compound scaling): глубина, ширина и разрешение входного изображения сети увеличиваются согласованно, по единому коэффициенту, а не по отдельности. Старшая модель семейства, EfficientNet-B7, достигла точности 84,4 % (top-1) / 97,1 % (top-5) на ImageNet, будучи при этом в 8,4 раза компактнее и в 6,1 раза быстрее на этапе вывода по сравнению с сопоставимой по точности предшествующей архитектурой.

Таблица 1.1 — Сравнение основных архитектур CNN

Архитектура	Год	Ключевая идея	Преимущества	Недостатки / ограничения
LeNet [2]	1998	Чередование свёртки и подвыборки; базовая схема CNN	Простота, малые вычислительные затраты, историческая основа всех последующих CNN	Ограниченная выразительная способность; неприменима для крупномасштабных задач
AlexNet [9]	2012	Глубокая сеть на GPU; ReLU; dropout	Резкий скачок точности на ImageNet; заложила современную парадигму обучения CNN	Большое число параметров (порядка 60 млн), значительная часть которых сосредоточена в полносвязных слоях
VGG [10]	2014	Глубина за счёт однородных свёрток 3×3	Простая, регулярная структура; хорошая переносимость признаков на другие задачи	Очень большое число параметров и высокая вычислительная стоимость

Архитектура	Год	Ключевая идея	Преимущества	Недостатки / ограничения
				по сравнению с более поздними архитектурами
GoogLeNet / Inception [11]	2014	Параллельные свёртки разного размера (Inception-модуль)	Эффективное использование вычислительных ресурсов при увеличении глубины/ширины	Более сложная и менее регулярная структура, усложняющая модификацию архитектуры
ResNet [12]	2016	Остаточные связи (residual connections)	Устойчивое обучение очень глубоких сетей; высокая точность; широкое распространение как база для переноса обучения	Рост глубины по-прежнему увеличивает вычислительные затраты и требования к памяти
DenseNet [13]	2017	Плотные связи между всеми слоями блока	Эффективное повторное использование признаков; меньше параметров при сопоставимой точности	Повышенный расход памяти на хранение конкатенированных карт признаков при обучении
MobileNet [14]	2017	Разделяемая по глубине свёртка	Низкая вычислительная стоимость; пригодна для мобильных/встраиваемых устройств; настраиваемый баланс точность/скорость	Как правило, уступает по точности крупным архитектурам на сложных задачах
EfficientNet [15]	2019	Согласованное (составное) масштабирование глубины, ширины и разрешения	Рекордное соотношение точности и вычислительных затрат среди сетей своего поколения	Поиск базовой архитектуры и коэффициентов масштабирования требует значительных вычислительных ресурсов на этапе проектирования

Из таблицы 1.1 видно, что развитие архитектур CNN не сводится к простому «наращиванию глубины»: после ResNet и DenseNet, показавших, что глубина сама по себе перестаёт быть узким местом благодаря остаточным и плотным связям, вектор развития сместился в сторону эффективности — MobileNet и EfficientNet предлагают не более точные, а более экономичные по вычислениям решения, зачастую жертвуя частью точности ради применимости на устройствах с ограниченными ресурсами [1, 14, 15]. Это наблюдение подтверждается и специализированными обзорами по отдельным прикладным областям, которые

отдельно указывают на MobileNet и EfficientNet как на предпочтительные архитектуры для встраиваемых и мобильных приложений [6].

1.3.3 Области практического применения CNN

Классификация изображений. Классическая задача, на которой отрабатывались практически все рассмотренные выше архитектуры: сети принимают на вход изображение целиком и относят его к одному из заранее определённых классов. Используются размеченные наборы изображений (ImageNet и аналогичные корпуса); CNN хорошо подходят для этой задачи благодаря способности автоматически извлекать иерархию признаков — от границ и текстур до целостных объектов — без ручного конструирования признаков [1, 9]. Типично применяются AlexNet, VGG, ResNet, EfficientNet; преимущество — высокая точность при достаточном объёме размеченных данных; ограничение — необходимость больших размеченных выборок и чувствительность к смещению распределения данных между обучением и эксплуатацией.

Обнаружение объектов. В отличие от классификации, здесь требуется не только определить класс объекта, но и локализовать его на изображении (как правило, ограничивающим прямоугольником). Современные детекторы делятся на двухэтапные (сначала предлагаются регионы-кандидаты, затем производится их классификация) и одноэтапные (регрессия координат и класса выполняется за один проход сети), а в последние годы — также на детекторы на основе трансформеров, часто комбинируемые со сверточными «хребтами» (backbone) на базе ResNet или EfficientNet [4]. CNN подходят для этой задачи благодаря эффективному извлечению многомасштабных признаков карт; преимущество — возможность работы в реальном времени на современных архитектурах; ограничения — снижение точности при обнаружении мелких и сильно перекрывающихся объектов, а также существенная зависимость итоговой производительности от качества и сбалансированности обучающей выборки [4].

Сегментация изображений. Задача попиксельной классификации, при которой каждому пикселю изображения присваивается метка класса (семантическая сегментация) либо метка конкретного экземпляра объекта (инстанс-сегментация). CNN применяются здесь в архитектурах кодировщик–

декодировщик, где сверточная часть последовательно сжимает пространственное разрешение, извлекая признаки, а затем декодирующая часть восстанавливает полное разрешение с попиксельной разметкой; типичные хребты — VGG, ResNet [1, 3]. Преимущество — высокая точность локализации границ объектов; ограничение — высокая вычислительная и ресурсная стоимость по сравнению с классификацией, а также необходимость дорогостоящей попиксельной разметки обучающих данных.

Медицинская диагностика и анализ медицинских изображений. CNN используются для классификации, обнаружения и сегментации патологий на снимках компьютерной томографии, магнитно-резонансной томографии, рентгенограммах, гистологических препаратах и изображениях сетчатки глаза [3]. Обзор Mienye et al. [3] показывает, что CNN применяются в диагностике заболеваний нервной, сердечно-сосудистой, дыхательной, пищеварительной и костно-мышечной систем, при этом чаще всего используются архитектуры на основе ResNet, а также специализированные сегментационные сети. CNN подходят для этой задачи благодаря способности выявлять признаки патологии, слабо заметные при визуальном анализе врачом; преимущество — потенциал повышения скорости и воспроизводимости диагностики; ключевое ограничение, отдельно подчёркиваемое в обзоре [3], — дефицит больших качественно размеченных медицинских наборов данных, что требует широкого использования переноса обучения (transfer learning) и ограничивает прямую переносимость моделей между клиниками с разным оборудованием.

Автономные транспортные средства. CNN — базовый компонент модульного конвейера восприятия окружающей обстановки (perception) в автономных автомобилях: обнаружение и классификация участников движения, разметки дорожного полотна, дорожных знаков и препятствий по данным камер, а также, в задачах сквозного (end-to-end) управления, — прямое отображение изображения с камеры в команды управления [5]. CNN подходят благодаря способности работать с потоком изображений в реальном времени; преимущество — высокая точность восприятия сцены при благоприятных условиях; ограничения, отдельно отмеченные в обзоре Grigorescu et al. [5], — вопросы безопасности и верифицируемости решений CNN, зависимость от

качества и разнообразия обучающих данных, а также высокие требования к вычислительной мощности и энергопотреблению бортового оборудования.

Робототехника. Помимо восприятия окружающей среды, CNN в робототехнике используются для оценки позы объектов, планирования схвата (grasping) и визуального сервоуправления, зачастую в связке с методами обучения с подкреплением [1]. Преимущество применения CNN — устойчивость к вариациям освещения и ракурса; ограничение — необходимость работы в реальном времени на бортовых вычислителях с ограниченным энергопотреблением, что часто вынуждает использовать лёгкие архитектуры (MobileNet) вместо более точных, но громоздких моделей.

Системы видеонаблюдения. CNN применяются для обнаружения аномального поведения, подсчёта людей и транспортных средств, а также для трекинга объектов в видеопотоке; типично совмещение детектора объектов на CNN с алгоритмами сопоставления треков между кадрами [4]. Преимущество — возможность непрерывного автоматического анализа больших объёмов видеоданных без участия оператора; ограничения — чувствительность к условиям освещённости и ракурсу камеры, а также вопросы конфиденциальности при обработке видеоданных.

Распознавание лиц. Специализированная задача классификации/верификации, в которой CNN обучаются формировать компактное признаковое представление (эмбеддинг) лица таким образом, чтобы изображения одного человека оказывались близки в признаковом пространстве, а разных людей — далеки [1]. Преимущество — высокая точность верификации при контролируемых условиях съёмки; ограничения — снижение точности при значительных изменениях ракурса, освещения и возраста, а также существенные этические и нормативные ограничения на использование подобных систем.

Промышленный контроль качества. CNN используются для автоматического обнаружения дефектов на поверхности изделий, сортировки продукции по внешним признакам и контроля соответствия изделий технологическим требованиям на основе изображений с промышленных камер. Показательным примером служит применение сверточной сети для классификации изображений семян сельскохозяйственных культур с целью их

сортировки на «годные» и «дефектные» на оптическом сепараторе [8]: в этой работе неглубокая CNN, обученная на ограниченной выборке изображений, полученных бытовой камерой, показала достаточную для практического применения точность классификации на тестовой выборке, что подтверждает применимость относительно простых архитектур CNN в задачах промышленного и сельскохозяйственного контроля качества при условии контролируемых условий съёмки. Преимущество применения CNN в этой области — снижение доли ручного контроля и повышение однородности принимаемых решений; ограничение, отмеченное в самой работе [8], — чувствительность точности классификации к качеству и объёму обучающей выборки, а также к условиям освещения при съёмке.

Анализ спутниковых и аэрокосмических изображений. CNN применяются для классификации типов земной поверхности, обнаружения объектов (зданий, транспортных средств, судов) и мониторинга изменений местности по мультиспектральным и панхроматическим снимкам [1, 4]. Преимущество — возможность автоматизированного анализа огромных площадей территории; ограничения — существенные отличия статистики спутниковых изображений (масштаб, спектральный состав, ориентация объектов) от изображений, на которых обучались стандартные архитектуры, что требует дообучения или специализированной адаптации моделей.

Обработка видео. Помимо кадрового применения CNN к видеопотоку (используемого, например, в видеонаблюдении), для собственно видеоаналитики применяются пространственно-временные свёртки и комбинации CNN с рекуррентными архитектурами для учёта временной динамики сцены [1]. Преимущество — возможность анализа не только содержания кадра, но и динамики движения; ограничение — существенно более высокая вычислительная и ресурсная стоимость по сравнению с обработкой отдельных изображений.

OCR и распознавание документов. CNN используются как для локализации текстовых областей на изображении документа, так и (обычно в сочетании с рекуррентными слоями или механизмом внимания) для распознавания последовательностей символов [1]. Преимущество —

устойчивость к вариациям шрифта, наклона и качества скана по сравнению с классическими методами на основе шаблонов; ограничение — снижение точности при низком качестве исходного изображения, нестандартных шрифтах и рукописном тексте.

1.3.4 Сравнительный анализ применения CNN

Таблица 1.2 — Сравнение областей применения CNN

Область	Тип данных	Основная задача	Преимущества CNN	Ограничения	Архитектуры
Классификация изображений	Отдельные изображения	Отнесение изображения к классу	Автоматическое извлечение иерархии признаков	Нужен большой размеченный набор данных	AlexNet, VGG, ResNet, EfficientNet
Обнаружение объектов	Изображения/видео	Локализация и классификация объектов	Многомасштабное извлечение признаков; работа в реальном времени	Проблемы с мелкими и перекрывающимися объектами	ResNet, EfficientNet (в составе детекторов)
Сегментация изображений	Изображения	Попиксельная разметка объектов	Точная локализация границ объектов	Высокая ресурсоёмкость; дорогая разметка данных	VGG/ResNet-хребты в схеме кодировщик-декодировщик
Медицинская диагностика	Медицинские снимки (КТ, МРТ, рентген и др.)	Классификация/сегментация патологий	Выявление слабозаметных признаков патологии	Дефицит больших размеченных медицинских выборок	ResNet и специализированные сегментационные сети
Автономный транспорт	Видеопоток с камер, датчики	Восприятие сцены, обнаружение препятствий	Работа с потоком изображений в реальном времени	Требования к безопасности, верифицируемости и энергопотреблению	Лёгкие и специализированные CNN-хребты
Промышленный контроль качества	Изображения с промышленных/фотокамер	Обнаружение дефектов, сортировка изделий	Снижение доли ручного контроля	Чувствительность к объёму выборки и условиям съёмки	Неглубокие специализированные CNN
OCR / документы	Сканы, фотографии документов	Локализация и распознавание текста	Устойчивость к вариациям шрифта и наклона	Снижение точности при низком качестве скана	CNN в сочетании с рекуррентными слоями/вниманием

Сопоставление областей применения, представленное в таблице 1.2, а также в разделе 1.3.3, позволяет сформулировать ряд обобщений.

В каких задачах CNN наиболее эффективны. Наибольшая эффективность CNN достигается в задачах, где (а) доступен достаточно большой размеченный набор данных и (б) искомый признак имеет выраженную

пространственную локальность — границы, текстуры, формы объектов. Этим объясняется устойчивый успех CNN в классификации изображений, обнаружении объектов и медицинской визуализации [1, 3, 4].

Где применение CNN имеет ограничения. Ограничения проявляются там, где выполняется хотя бы одно из условий: обучающих данных объективно мало и их сложно собрать (узкоспециализированная медицинская диагностика, промышленный контроль на нестандартной продукции), либо цена ошибки крайне высока и требуется дополнительная верифицируемость решений (автономный транспорт), либо статистика данных сильно отличается от привычной для типовых архитектур (спутниковые снимки) [3, 5].

Выбор лёгких архитектур. Более лёгкие архитектуры (MobileNet, EfficientNet младших конфигураций) предпочтительны там, где решение должно исполняться на встраиваемом или мобильном оборудовании в реальном времени при ограниченном энергопотреблении, — в робототехнике, бортовых системах транспортных средств, системах видеонаблюдения с большим числом камер [5, 6].

Оправданность глубоких и вычислительно сложных моделей. Применение глубоких архитектур (ResNet, DenseNet, старшие конфигурации EfficientNet) оправдано, когда решение исполняется на серверном оборудовании или в оффлайн-режиме и когда цена дополнительных вычислений существенно ниже цены ошибки классификации/диагностики — например, в медицинской визуализации, где вычисления, как правило, не критичны по времени, но критичны по точности [3].

Влияние аппаратных требований на выбор архитектуры. Как отдельно отмечается в обзоре по сжатию моделей [6], при развёртывании CNN на периферийных (edge) устройствах определяющими становятся не только теоретическая вычислительная сложность модели, но и фактические задержки, энергопотребление и объём оперативной памяти конкретного устройства, что делает выбор архитектуры неотделимым от выбора целевой аппаратной платформы.

Влияние размера и качества датасета на результат. Во всех рассмотренных прикладных обзорах подчёркивается прямая связь между

объёмом и качеством размеченных данных и итоговой точностью модели: в условиях ограниченной выборки (медицинская визуализация, промышленный контроль на нестандартной продукции) перенос обучения с предварительно обученных на больших датасетах моделей становится не факультативным приёмом, а практически обязательным условием получения работоспособного решения [3, 8].

Проблемы переноса CNN из исследовательской среды в реальные системы. Обзоры по автономному вождению и медицинской визуализации сходятся в том, что модель, показавшая высокую точность на тестовой выборке в контролируемых условиях, при переносе в реальную эксплуатационную среду сталкивается с изменением распределения входных данных, требованиями к скорости отклика в реальном времени и необходимостью объяснимости принимаемых решений — факторами, которые редко в полной мере учитываются на этапе разработки модели [3, 5].

1.3.5 Современные тенденции развития CNN

Наряду с развитием собственно архитектур классификации, в современной литературе прослеживается устойчивый тренд на повышение практической применимости CNN за счёт методов оптимизации моделей.

Лёгкие CNN и edge AI. Помимо специально спроектированных лёгких архитектур (MobileNet, EfficientNet), в литературе отдельно рассматривается более широкий класс методов, направленных на развёртывание CNN непосредственно на периферийных устройствах (edge AI) — там, где передача данных на сервер невозможна или нежелательна по соображениям задержки, пропускной способности сети или конфиденциальности данных [6].

Pruning (прореживание). Метод удаления из обученной сети весов или целых структурных единиц (нейронов, каналов, фильтров), вносящих минимальный вклад в итоговый результат, с целью уменьшения размера модели и вычислительных затрат при минимальной потере точности [6]. Практическое значение прореживания заключается в возможности взять уже обученную «тяжёлую» модель и адаптировать её под ограниченные ресурсы конкретного устройства без полного повторного обучения с нуля.

Quantization (квантование). Снижение разрядности представления весов и активаций сети (например, переход от 32-битных чисел с плавающей запятой к 8-битным целым числам), что уменьшает объём занимаемой памяти и ускоряет вычисления на аппаратных платформах с поддержкой низкоразрядной арифметики [6]. Квантование особенно значимо при развёртывании CNN на программируемых логических интегральных схемах (ПЛИС) и специализированных нейросетевых ускорителях, где переход к целочисленным вычислениям напрямую определяет возможность размещения модели в доступном объёме памяти устройства [8].

Knowledge distillation (дистилляция знаний). Метод, при котором компактная модель-«ученик» обучается воспроизводить не только итоговые метки, но и более информативные «мягкие» предсказания крупной, заранее обученной модели-«учителя», за счёт чего ученик достигает более высокого качества, чем при обучении исключительно на исходных метках классов [7]. Практическая значимость дистилляции знаний состоит в возможности перенести часть «опыта» большой модели в компактную архитектуру, пригодную для развёртывания на ограниченном по ресурсам оборудовании, не жертвуя точностью в той мере, в какой это происходит при простом уменьшении размера модели.

Transfer learning (перенос обучения). Использование весов, полученных при обучении модели на большом универсальном наборе данных, в качестве отправной точки для обучения на существенно меньшем наборе данных целевой предметной области [1, 3]. Практическое значение переноса обучения особенно велико в медицинской визуализации и промышленном контроле качества, где сбор больших размеченных выборок объективно затруднён [3, 8].

Комбинирование CNN с другими архитектурами. В задачах, требующих учёта временной динамики (обработка видео) или моделирования дальних зависимостей на изображении (некоторые современные детекторы объектов), CNN всё чаще используются не самостоятельно, а в сочетании с рекуррентными сетями или архитектурами на основе механизма внимания (трансформерами), выступая эффективным «извлекателем» локальных пространственных признаков в составе более крупной гибридной модели [4].

Применение CNN в системах реального времени. Для систем видеонаблюдения, автономного транспорта и промышленного контроля качества критичным параметром наряду с точностью становится задержка обработки одного кадра; это обстоятельство напрямую формирует спрос на лёгкие архитектуры и методы сжатия моделей, рассмотренные выше [5, 6].

Проблемы интерпретируемости. Обзоры по медицинской визуализации и автономному вождению отдельно указывают на сложность содержательного объяснения решений, принимаемых глубокими CNN, что становится существенным барьером для их внедрения в задачах с высокой ценой ошибки и необходимостью обоснования принятого решения перед экспертом или регулятором [3, 5].

Устойчивость и надёжность моделей. Отдельного внимания в литературе заслуживает вопрос устойчивости CNN к изменению условий эксплуатации по сравнению с условиями обучения (смещение распределения данных, состязательные возмущения входного изображения), что напрямую влияет на надёжность систем, работающих в неконтролируемой среде, — прежде всего автономного транспорта и систем видеонаблюдения [5].

Таблица 1.3 — Современные методы оптимизации CNN

Метод	Суть метода	Практическое значение
Pruning	Удаление малозначимых весов/каналов обученной сети	Сокращение размера и вычислительных затрат готовой модели
Quantization	Снижение разрядности весов и активаций	Ускорение вычислений и экономия памяти на целевом устройстве
Knowledge distillation	Обучение компактной модели на «мягких» предсказаниях крупной модели	Повышение точности компактных моделей для развёртывания на слабом оборудовании
Transfer learning	Дообучение предобученной модели на данных целевой задачи	Снижение требований к объёму размеченных данных целевой задачи

1.4 Выводы и рекомендации

Проведённый анализ профессиональной литературы по теме «Анализ сверточных нейронных сетей и областей их практического применения» позволяет сформулировать следующие основные результаты.

Во-первых, развитие архитектур CNN прошло путь от простых неглубоких сетей (LeNet) через архитектуры, максимизирующие точность за счёт увеличения глубины и объёма вычислений (AlexNet, VGG, GoogLeNet, ResNet, DenseNet), к архитектурам, оптимизированным по соотношению точности и вычислительных затрат (MobileNet, EfficientNet) [1]. Ключевыми техническими решениями, обеспечившими этот переход, стали остаточные связи (ResNet), плотные связи (DenseNet), разделяемая по глубине свёртка (MobileNet) и согласованное масштабирование глубины, ширины и разрешения (EfficientNet).

Во-вторых, к безусловным преимуществам CNN как класса моделей относится способность автоматически извлекать иерархию пространственных признаков без ручного конструирования, что обеспечило их успех в широком спектре задач — от классификации изображений и обнаружения объектов до медицинской диагностики и промышленного контроля качества [1, 3, 4, 8]. К основным недостаткам и ограничениям технологии следует отнести: высокую потребность в объёме и качестве размеченных обучающих данных; существенные вычислительные затраты глубоких архитектур, ограничивающие их применение на встраиваемом оборудовании; недостаточную интерпретируемость принимаемых решений; чувствительность к изменению распределения данных при переносе модели из исследовательской среды в реальную эксплуатацию [3, 5].

В-третьих, наиболее перспективными с точки зрения практического внедрения представляются архитектуры и методы, нацеленные на повышение эффективности, а не только точности моделей: EfficientNet и MobileNet как самостоятельные архитектурные решения, а также pruning, quantization, knowledge distillation и transfer learning как методы адаптации уже обученных моделей под конкретные условия эксплуатации [6, 7].

Применение CNN представляется наиболее оправданным в задачах с выраженной пространственной структурой данных, где доступен достаточный объём обучающих данных или имеется возможность использовать перенос обучения с крупных предобученных моделей, — прежде всего в классификации и сегментации изображений, обнаружении объектов и медицинской визуализации [1, 3, 4]. Ограничением технологии остаются задачи с малым объёмом доступных

данных, высокой ценой ошибки и требованием объяснимости решений, где применение CNN должно сопровождаться дополнительными мерами контроля качества и, как правило, переносом обучения либо привлечением экспертной проверки [3, 5].

На основании проведённого анализа можно сформулировать следующие практические рекомендации по выбору архитектуры CNN в зависимости от поставленной задачи:

1. При наличии большого размеченного набора данных и отсутствии жёстких ограничений на вычислительные ресурсы (серверное исполнение, оффлайн-обработка) целесообразно использовать глубокие архитектуры на основе остаточных или плотных связей (ResNet, DenseNet) либо старшие конфигурации EfficientNet, обеспечивающие наивысшую точность.
2. При необходимости развёртывания модели на мобильном или встраиваемом устройстве с ограничениями по памяти, энергопотреблению и задержке отклика предпочтение следует отдавать архитектурам семейств MobileNet или младших конфигураций EfficientNet, при необходимости — в сочетании с прореживанием и квантованием уже обученной модели.
3. При ограниченном объёме размеченных данных целевой задачи (типично для медицинской визуализации и промышленного контроля качества на нестандартной продукции) рационально использовать перенос обучения с предобученных на крупных датасетах моделей вместо обучения архитектуры «с нуля».
4. Для задач, требующих одновременно высокой точности крупной модели и экономичности исполнения на конечном устройстве, целесообразно применять дистилляцию знаний — перенос «опыта» большой предобученной модели в компактную архитектуру, предназначенную для развёртывания.
5. Для задач с высокой ценой ошибки и требованием обоснования принятого решения (автономный транспорт, медицинская диагностика) выбор архитектуры должен дополняться отдельной

оценкой устойчивости модели к смещению распределения данных и, где это возможно, методами повышения интерпретируемости принимаемых решений.

ЗАКЛЮЧЕНИЕ

В ходе выполнения данного этапа учебной (аналитической) практики был проведён анализ профессиональной информации по индивидуальной теме «Анализ сверточных нейронных сетей и областей их практического применения».

Были решены все поставленные задачи исследования: раскрыт принцип работы сверточных нейронных сетей, включая структуру сети, операцию свёртки, функции активации, слои подвыборки и методы регуляризации; изучены и систематизированы восемь основных архитектур CNN (LeNet, AlexNet, VGG, GoogLeNet/Inception, ResNet, DenseNet, MobileNet, EfficientNet) с их сравнением по единым критериям; рассмотрены двенадцать областей практического применения CNN с указанием решаемых задач, используемых данных, применимых архитектур, преимуществ и ограничений; проведён сравнительный анализ областей применения и современных тенденций развития технологии (лёгкие архитектуры, edge AI, pruning, quantization, knowledge distillation, transfer learning).

По результатам анализа сформулированы выводы о преимуществах CNN (автоматическое извлечение иерархии пространственных признаков, широкая применимость) и их ограничениях (потребность в объёме размеченных данных, вычислительные затраты глубоких архитектур, недостаточная интерпретируемость решений), выделены наиболее перспективные с точки зрения практического внедрения архитектуры и методы (EfficientNet, MobileNet, pruning, quantization, knowledge distillation, transfer learning), а также сформулированы практические рекомендации по выбору архитектуры CNN в зависимости от объёма доступных данных, вычислительных ограничений целевого устройства и цены ошибки решаемой задачи.

Работа над практической частью задания, связанной с операционными системами, будет представлена на следующем этапе.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Alzubaidi L., Zhang J., Humaidi A.J., Al-Dujaili A., Duan Y., Al-Shamma O., Santamaría J., Fadhel M.A., Al-Amidie M., Farhan L. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions // *Journal of Big Data*. — 2021. — Vol. 8, No. 53. DOI: 10.1186/s40537-021-00444-8.
2. LeCun Y., Bottou L., Bengio Y., Haffner P. Gradient-based learning applied to document recognition // *Proceedings of the IEEE*. — 1998. — Vol. 86, No. 11. — P. 2278–2324. DOI: 10.1109/5.726791.
3. Mienye I.D., Swart T.G., Obaido G., Jordan M., Ilono P. Deep Convolutional Neural Networks in Medical Image Analysis: A Review // *Information*. — 2025. — Vol. 16, No. 3, Art. 195. DOI: 10.3390/info16030195.
4. Amjoud A.B., Amrouch M. Object Detection Using Deep Learning, CNNs and Vision Transformers: A Review // *IEEE Access*. — 2023. — Vol. 11. — P. 35479–35516. DOI: 10.1109/ACCESS.2023.3266093.
5. Grigorescu S., Trasnea B., Cocias T., Macesanu G. A survey of deep learning techniques for autonomous driving // *Journal of Field Robotics*. — 2020. — Vol. 37, No. 3. — P. 362–386. DOI: 10.1002/rob.21918.
6. Deng L., Li G., Han S., Shi L., Xie Y. Model Compression and Hardware Acceleration for Neural Networks: A Comprehensive Survey // *Proceedings of the IEEE*. — 2020. — Vol. 108, No. 4. — P. 485–532. DOI: 10.1109/JPROC.2020.2976475.
7. Gou J., Yu B., Maybank S.J., Tao D. Knowledge Distillation: A Survey // *International Journal of Computer Vision*. — 2021. — Vol. 129, No. 6. — P. 1789–1819. DOI: 10.1007/s11263-021-01453-z.
8. Деркачев В.А., Бахчевников В.В., Бакуменко А.Н. Классификатор изображений семян сельскохозяйственных культур с использованием сверточной нейронной сети // *Известия ЮФУ. Технические науки*. — 2020. — № 4. — С. 32–39. DOI: 10.18522/2311-3103-2020-4-32-39.

9. Krizhevsky A., Sutskever I., Hinton G.E. ImageNet classification with deep convolutional neural networks // Communications of the ACM. — 2017. — Vol. 60, No. 6. — P. 84–90. DOI: 10.1145/3065386.
10. Simonyan K., Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition // International Conference on Learning Representations (ICLR). — 2015. — arXiv:1409.1556.
11. Szegedy C., Liu W., Jia Y., Sermanet P., Reed S., Anguelov D., Erhan D., Vanhoucke V., Rabinovich A. Going Deeper with Convolutions // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2015. — P. 1–9. DOI: 10.1109/CVPR.2015.7298594.
12. He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2016. — P. 770–778. DOI: 10.1109/CVPR.2016.90.
13. Huang G., Liu Z., Van Der Maaten L., Weinberger K.Q. Densely Connected Convolutional Networks // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2017. — P. 2261–2269. DOI: 10.1109/CVPR.2017.243.
14. Howard A.G., Zhu M., Chen B., Kalenichenko D., Wang W., Weyand T., Andreetto M., Adam H. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. — 2017. — arXiv:1704.04861.
15. Tan M., Le Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks // Proceedings of the 36th International Conference on Machine Learning (ICML). — 2019. — arXiv:1905.11946.