

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	2
1 Анализ профессиональной информации по индивидуальной теме	3
1.1 Постановка задачи	3
1.2 Поиск и анализ профессиональной информации	4
1.3 Результаты исследования	5
1.3.1 Принцип работы CNN	5
1.3.2 Основные архитектуры CNN	6
1.3.3 Области практического применения CNN	8
1.3.4 Сравнительный анализ применения CNN	10
1.3.5 Современные тенденции развития CNN	11
1.4 Выводы и рекомендации	13
ЗАКЛЮЧЕНИЕ	15
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	16

ВВЕДЕНИЕ

Целью аналитической практики являлось приобретение и закрепление практических навыков в двух направлениях: (1) поиск, изучение и систематизация информации по индивидуальной теме исследования и (2) практическая работа со средствами операционных систем в рамках мероприятий компании-партнёра. Индивидуальным заданием на практику была определена тема «Анализ сверточных нейронных сетей и областей их практического применения».

Задачи практики: изучить принцип работы сверточных нейронных сетей; найти и проанализировать литературу по основным архитектурам CNN и областям их применения; провести сравнительный анализ архитектур и областей применения по единым критериям; сформулировать выводы и рекомендации по выбору архитектуры CNN в зависимости от решаемой задачи.

Актуальность темы обусловлена тем, что сверточные нейронные сети остаются базовой технологией компьютерного зрения и лежат в основе большинства промышленных систем классификации изображений, обнаружения объектов и сегментации — от медицинской диагностики до автономного транспорта. Рост точности моделей сопровождается ростом требований к вычислительным ресурсам, что делает обоснованный выбор архитектуры практически значимой задачей.

Структура настоящего этапа отчёта соответствует индивидуальному заданию и включает анализ профессиональной информации по индивидуальной теме (раздел 1), заключение и список использованных источников.

1 АНАЛИЗ ПРОФЕССИОНАЛЬНОЙ ИНФОРМАЦИИ ПО ИНДИВИДУАЛЬНОЙ ТЕМЕ

1.1 Постановка задачи

Индивидуальной темой практики является «Анализ сверточных нейронных сетей и областей их практического применения». Сверточные нейронные сети (CNN) — класс архитектур глубокого обучения, приспособленных для обработки данных с выраженной пространственной структурой, прежде всего изображений и видео. В отличие от полносвязных сетей, CNN используют операцию свёртки с разделяемыми весами и локальные рецептивные поля, что резко сокращает число параметров и обеспечивает частичную инвариантность к сдвигу и масштабу входных данных [1, 2].

Актуальность темы определяется тем, что CNN остаются стандартом решения задач компьютерного зрения и лежат в основе промышленных систем в разных отраслях — от медицинской диагностики до автономного транспорта. Семейство архитектур CNN неоднородно: одни модели (VGG, ResNet, DenseNet) ориентированы на максимальную точность и требуют серверных GPU-кластеров, другие (MobileNet, EfficientNet) спроектированы для мобильных и встраиваемых устройств с жёсткими ограничениями по памяти и энергопотреблению. Обоснованный выбор архитектуры под задачу требует систематического сравнения этих решений.

Цель исследования — на основании анализа литературы систематизировать сведения об основных архитектурах CNN и провести сравнительный анализ областей их практического применения для формирования рекомендаций по выбору архитектуры.

Задачи исследования:

1. Раскрыть принцип работы CNN: структуру, операцию свёртки, функции активации, слои подвыборки, полносвязные слои, процесс обучения и регуляризацию.
2. Систематизировать сведения об основных архитектурах CNN (LeNet, AlexNet, VGG, GoogLeNet/Inception, ResNet, DenseNet, MobileNet, EfficientNet) и сравнить их по единым критериям.

3. Рассмотреть области практического применения CNN (классификация изображений, обнаружение объектов, сегментация, медицинская диагностика, автономный транспорт, робототехника, видеонаблюдение, распознавание лиц, промышленный контроль качества, анализ спутниковых изображений, обработка видео, OCR) с указанием решаемой задачи, архитектур, преимуществ и ограничений.
4. Провести сравнительный анализ областей применения и современных тенденций развития CNN (лёгкие архитектуры, edge AI, pruning, quantization, knowledge distillation, transfer learning).
5. Сформулировать выводы и рекомендации по выбору архитектуры CNN в зависимости от задачи.

Объект исследования — сверточные нейронные сети как класс архитектур глубокого обучения. Предмет — сравнительные характеристики архитектур CNN и особенности их применения.

Критерии сравнения: год появления и ключевая идея архитектуры; глубина сети и порядок числа параметров (где подтверждено источниками); вычислительная сложность и требования к памяти; применимость для устройств с ограниченными ресурсами; типичные области использования; преимущества и недостатки.

1.2 Поиск и анализ профессиональной информации

Поиск проводился по трём направлениям: оригинальные публикации, впервые предложившие основные архитектуры CNN; обзорные статьи по их развитию и применению; публикации по оптимизации моделей и аппаратным платформам для развёртывания. Использовались базы arXiv, IEEE Xplore, Scopus/Web of Science, elibrary.ru и ЭБС МИРЭА; источники отбирались по рецензируемости издания, наличию DOI и соответствию разделам задания.

Большинство источников — обзорные статьи и учебные издания 2020–2025 гг.; исключение сделано для восьми оригинальных публикаций по архитектурам из раздела 1.3.2, вводящих идеи, на которые ссылаются все более поздние обзоры,

— это соответствует оговорённому в задании исключению для фундаментальных работ.

Наиболее полезными оказались обзор Alzubaidi et al. [1], охватывающий развитие архитектур CNN и систематизирующий области их применения, обзор по медицинской визуализации Mienye et al. [3] и статья Деркачева и др. [4] — пример отечественной публикации о прикладной задаче сортировки сельскохозяйственной продукции.

Позиции авторов согласуются в отношении траектории развития CNN — от неглубоких сетей (LeNet, AlexNet) к очень глубоким (VGG, ResNet, DenseNet) и далее к архитектурам, оптимизированным по соотношению «точность/вычислительные затраты» (MobileNet, EfficientNet) [1] единого мнения об «оптимальной» архитектуре нет — выбор зависит от предметной области и аппаратных ограничений [1, 3].

Направления развития CNN, прослеживающиеся в литературе: рост внимания к лёгким архитектурам и методам сжатия моделей — pruning, квантование, дистилляция знаний; перенос обучения, особенно в медицинской визуализации [3] развёртывание CNN на встраиваемых платформах (edge AI) в промышленном контроле качества и автономных транспортных средствах [1, 4].

1.3 Результаты исследования

1.3.1 Принцип работы CNN

Сверточная нейронная сеть — последовательность слоёв, каждый из которых преобразует входной тензор в новый признаковый тензор. Типовая структура, предложенная в архитектуре LeNet [2], включает чередование сверточных слоёв, слоёв подвыборки и завершающих полносвязных слоёв с функцией softmax на выходе [1, 2].

Операция свёртки и карты признаков. Сверточный слой скользящим поэлементным умножением фрагмента входного тензора на матрицу весов (фильтр) с суммированием произведений формирует карту признаков — высокие значения соответствуют участкам, похожим на паттерн фильтра. Поскольку фильтр применяется ко всем участкам изображения (разделяемые веса), число параметров слоя на порядки меньше, чем в полносвязном слое аналогичной

«широты» [1] набор из десятков–сотен фильтров выделяет признаки разного уровня — от границ в первых слоях до сложных паттернов в глубоких.

Функции активации. После свёртки применяется нелинейная функция активации. Начиная с AlexNet [5] стандартом стала ReLU ($f(x) = \max(0, x)$), которая не насыщается при положительных значениях аргумента и ускоряет обучение глубоких сетей.

Слои подвыборки уменьшают размерность карт признаков (чаще всего выбором максимума), снижая вычислительную нагрузку и повышая устойчивость сети к сдвигам изображения.

Полносвязные слои преобразуют извлечённые признаки в вектор вероятностей классов через softmax; обучение — минимизация функции потерь (обычно кросс-энтропии) методом обратного распространения ошибки и градиентного спуска.

Переобучение и регуляризация. Из-за большого числа параметров глубокие CNN подвержены переобучению. Применяются: регуляризация весов (L1/L2), dropout (впервые в AlexNet [5]), batch normalization, аугментация данных и перенос обучения [1, 3].

1.3.2 Основные архитектуры CNN

Развитие архитектур CNN шло по пути увеличения глубины сети при сохранении обучаемости и вычислительной эффективности, а с середины 2010-х годов — также по пути проектирования лёгких архитектур для мобильных устройств [1].

LeNet [2] — первая практически применённая сверточная архитектура (распознавание рукописных цифр): чередование свёртки и подвыборки с полносвязными слоями на выходе; заложила базовые принципы построения CNN.

AlexNet [5] — победитель ILSVRC 2012 (top-5 ошибка 15,3 % против 26,2 % у второго места); пять сверточных и три полносвязных слоя, порядка 60 млн параметров, ReLU, dropout, обучение на GPU.

VGG [6] — семейство архитектур (VGG-11...VGG-19) на основе однородных свёрток 3×3 , занявшее первое и второе места в ILSVRC 2014 при глубине 16–19 слоёв.

GoogLeNet / Inception [7] — архитектура глубиной 22 слоя (победитель ILSVRC 2014) с модулем Inception, параллельно применяющим свёртки разного размера (1×1, 3×3, 5×5).

ResNet [8] — архитектура с остаточными связями (блок обучается предсказывать поправку к входному сигналу), устранившая затухание градиента и впервые позволившая обучать сети глубиной в сотни слоёв.

DenseNet [9] — каждый слой плотного блока получает конкатенацию карт признаков всех предыдущих слоёв блока ($\frac{L(L+1)}{2}$ связей вместо L), что сокращает число параметров при сопоставимой или более высокой точности по сравнению с ResNet.

MobileNet [10] — семейство архитектур для мобильных устройств на основе разделяемой по глубине свёртки с двумя гиперпараметрами баланса задержки и точности.

EfficientNet [11] — семейство (B0...B7) на основе составного масштабирования глубины, ширины и разрешения; EfficientNet-B7 достигла 84,4 % (top-1) на ImageNet, будучи в 8,4 раза компактнее и в 6,1 раза быстрее предшествующей архитектуры.

Таблица 1.1 — Сравнение основных архитектур CNN

Архитектура	Год	Ключевая идея	Преимущества	Недостатки / ограничения
LeNet [2]	1998	Чередование свёртки и подвыборки; базовая схема CNN	Простота, малые вычислительные затраты, историческая основа всех последующих CNN	Ограниченная выразительная способность; неприменима для крупномасштабных задач
AlexNet [5]	2012	Глубокая сеть на GPU; ReLU; dropout	Резкий скачок точности на ImageNet; заложила современную парадигму обучения CNN	Большое число параметров (порядка 60 млн), значительная часть которых в полносвязных слоях
VGG [6]	2014	Глубина за счёт однородных свёрток 3×3	Простая, регулярная структура; хорошая переносимость признаков на другие задачи	Очень большое число параметров и высокая вычислительная стоимость
GoogLeNet / Inception [7]	2014	Параллельные свёртки разного размера (Inception-модуль)	Эффективное использование вычислительных ресурсов при увеличении глубины/ширины	Более сложная и менее регулярная структура, усложняющая модификацию

Архитектура	Год	Ключевая идея	Преимущества	Недостатки / ограничения
ResNet [8]	2016	Остаточные связи	Устойчивое обучение очень глубоких сетей; высокая точность; база для переноса обучения	Рост глубины по-прежнему увеличивает вычислительные затраты и требования к памяти
DenseNet [9]	2017	Плотные связи между всеми слоями блока	Эффективное повторное использование признаков; меньше параметров при сопоставимой точности	Повышенный расход памяти на хранение карт признаков при обучении
MobileNet [10]	2017	Разделяемая по глубине свёртка	Низкая вычислительная стоимость; пригодна для мобильных устройств; баланс точность/скорость	Как правило, уступает по точности крупным архитектурам
EfficientNet [11]	2019	Согласованное масштабирование глубины, ширины и разрешения	Рекордное соотношение точности и вычислительных затрат среди сетей своего поколения	Поиск коэффициентов масштабирования требует значительных вычислений при проектировании

Развитие архитектур CNN не сводится к «наращиванию глубины»: после ResNet и DenseNet, показавших, что глубина перестаёт быть узким местом благодаря остаточным и плотным связям, вектор развития сместился в сторону эффективности — MobileNet и EfficientNet предлагают не более точные, а более экономичные решения, жертвуя частью точности ради применимости на устройствах с ограниченными ресурсами [1, 10, 11].

1.3.3 Области практического применения CNN

Классификация изображений. Сеть относит изображение целиком к одному из заданных классов на размеченных наборах данных (ImageNet и аналоги), автоматически извлекая иерархию признаков без ручного конструирования [1, 5]. Применяются AlexNet, VGG, ResNet, EfficientNet; преимущество — высокая точность при достаточном объёме данных; ограничение — потребность в больших размеченных выборках.

Обнаружение объектов. Требуется определить класс объекта и локализовать его на изображении; детекторы делятся на двухэтапные и одноэтапные, часто со сверточным «хребтом» на базе ResNet или EfficientNet

[1]. Преимущество — работа в реальном времени; ограничение — снижение точности на мелких и перекрывающихся объектах.

Сегментация изображений. Попиксельная разметка объектов в архитектурах кодировщик–декодировщик с хребтами VGG, ResNet [1, 3]. Преимущество — точная локализация границ; ограничение — высокая ресурсоёмкость и дорогая по픽сельная разметка данных.

Медицинская диагностика. CNN классифицируют, обнаруживают и сегментируют патологии на снимках КТ, МРТ, рентгенограммах и снимках сетчатки, чаще всего на основе ResNet [3]. Преимущество — выявление слабозаметных признаков патологии; ограничение — дефицит больших размеченных медицинских выборок, что требует переноса обучения [3].

Автономные транспортные средства. CNN — базовый компонент восприятия обстановки: обнаружение участников движения, разметки и препятствий по камерам. Преимущество — работа в реальном времени; ограничения — требования к безопасности решений и энергопотреблению оборудования.

Робототехника. CNN используются для оценки позы объектов и визуального сервоуправления [1]. Преимущество — устойчивость к вариациям освещения; ограничение — необходимость лёгких архитектур (MobileNet) на бортовых вычислителях.

Системы видеонаблюдения. CNN применяются для обнаружения аномального поведения и трекинга объектов в видеопотоке. Преимущество — непрерывный анализ больших объёмов видео без оператора; ограничения — чувствительность к освещённости и вопросы конфиденциальности.

Распознавание лиц. CNN формируют компактный эмбединг лица так, чтобы изображения одного человека были близки в признаковом пространстве [1]. Преимущество — высокая точность при контролируемой съёмке; ограничения — снижение точности при смене ракурса и возраста, этические ограничения.

Промышленный контроль качества. CNN обнаруживают дефекты и сортируют продукцию по изображениям с промышленных камер, например при классификации изображений семян сельскохозяйственных культур

на оптическом сепараторе [4], где неглубокая CNN на ограниченной выборке показала достаточную для практики точность. Ограничение [4] — чувствительность к объёму выборки и условиям освещения.

Анализ спутниковых изображений. CNN классифицируют типы земной поверхности и обнаруживают объекты по мультиспектральным снимкам [1]. Преимущество — анализ больших территорий; ограничение — отличие статистики таких снимков от изображений, на которых обучались стандартные архитектуры.

Обработка видео. Используются пространственно-временные свёртки и комбинации CNN с рекуррентными архитектурами для учёта динамики сцены [1]. Преимущество — анализ движения, а не только содержания кадра; ограничение — более высокая вычислительная стоимость.

OCR и распознавание документов. CNN локализуют текстовые области и (с рекуррентными слоями или вниманием) распознают символы [1]. Преимущество — устойчивость к вариациям шрифта и наклона; ограничение — снижение точности при низком качестве скана.

1.3.4 Сравнительный анализ применения CNN

Таблица 1.2 — Сравнение областей применения CNN

Область	Тип данных	Основная задача	Преимущества CNN	Ограничения	Архитектуры
Классификация изображений	Отдельные изображения	Отнесение изображения к классу	Автоматическое извлечение иерархии признаков	Нужен большой размеченный набор данных	AlexNet, VGG, ResNet, EfficientNet
Обнаружение объектов	Изображения/видео	Локализация и классификация объектов	Многомасштабное извлечение признаков; работа в реальном времени	Проблемы с мелкими и перекрывающимися объектами	ResNet, EfficientNet (в составе детекторов)
Сегментация изображений	Изображения	Попиксельная разметка объектов	Точная локализация границ объектов	Высокая ресурсоёмкость; дорогая разметка данных	VGG/ResNet-хребты в схеме кодировщик-декодировщик
Медицинская диагностика	Медицинские снимки (КТ, МРТ, рентген и др.)	Классификация/сегментация патологий	Выявление слабозаметных признаков патологии	Дефицит больших размеченных медицинских выборок	ResNet и специализированные сегментационные сети
Автономный транспорт	Видеопоток с камер, датчики	Восприятие сцены, обнаружение препятствий	Работа с потоком изображений в реальном времени	Требования к безопасности, верифицируемости и энергопотреблению	Лёгкие и специализированные CNN-хребты

Область	Тип данных	Основная задача	Преимущества CNN	Ограничения	Архитектуры
Промышленный контроль качества	Изображения с промышленных/фотокамер	Обнаружение дефектов, сортировка изделий	Снижение доли ручного контроля	Чувствительность к объёму выборки и условиям съёмки	Неглубокие специализированные CNN
OCR / документы	Сканы, фотографии документов	Локализация и распознавание текста	Устойчивость к вариациям шрифта и наклона	Снижение точности при низком качестве скана	CNN в сочетании с рекуррентными слоями/вниманием

Сопоставление областей применения (таблица 1.2, раздел 1.3.3) даёт ряд обобщений. CNN наиболее эффективны там, где доступен большой размеченный набор данных и признак имеет выраженную пространственную локальность, — в классификации изображений, обнаружении объектов и медицинской визуализации [1, 3] ограничения проявляются при малом объёме данных, высокой цене ошибки (автономный транспорт) или сильном отличии статистики данных от типовой (спутниковые снимки) [3].

Выбор архитектуры связан с аппаратной платформой: лёгкие архитектуры (MobileNet, младшие EfficientNet) предпочтительны для встраиваемого и мобильного оборудования — в робототехнике, транспорте, видеонаблюдении с множеством камер [1, 12] глубокие (ResNet, DenseNet, старшие EfficientNet) оправданы при серверном или оффлайн-исполнении, когда цена ошибки выше цены вычислений, — например, в медицинской визуализации [3]. При развёртывании на периферийных устройствах определяющими становятся не теоретическая сложность модели, а фактические задержки, энергопотребление и память платформы [12].

При ограниченной выборке (медицинская визуализация, нестандартная продукция) перенос обучения становится практически обязательным условием работоспособного решения [3, 4], а при переносе модели из контролируемых условий в эксплуатацию она сталкивается со смещением распределения данных и требованиями к скорости отклика — факторами, редко учитываемыми при разработке [3].

1.3.5 Современные тенденции развития CNN

Наряду с развитием архитектур классификации прослеживается тренд на повышение практической применимости CNN за счёт оптимизации моделей и специализации вычислительных платформ [1, 12].

Сжатие моделей: pruning и quantization. Pruning удаляет из обученной сети веса или структурные единицы с минимальным вкладом в результат, адаптируя уже обученную модель под ограниченные ресурсы без обучения с нуля. Quantization снижает разрядность весов и активаций (например, до 8-битных целых), экономя память и ускоряя вычисления — особенно на ПЛИС и специализированных платформах [1, 12].

Дистилляция знаний и перенос обучения. Knowledge distillation обучает компактную модель-«ученик» на «мягких» предсказаниях крупной модели-«учителя», перенося часть её «опыта» без потерь точности, характерных для простого уменьшения размера модели. Transfer learning использует веса, полученные на большом датасете, как отправную точку для обучения на меньшем наборе данных целевой задачи — особенно значимо в медицине и промконтроле качества [1, 3, 4].

Гибридные архитектуры и реальное время. В задачах с временной динамикой (видео) или дальними зависимостями CNN сочетают с рекуррентными сетями или трансформерами как «извлекатель» локальных признаков [1]. Для видеонаблюдения, транспорта и промконтроля наряду с точностью критична задержка обработки кадра, что формирует спрос на лёгкие архитектуры и сжатие моделей [1, 12].

Интерпретируемость и устойчивость. Сложность объяснения решений глубоких CNN — барьер для их внедрения в задачах с высокой ценой ошибки [3] устойчивость к изменению условий эксплуатации напрямую влияет на надёжность систем в неконтролируемой среде.

Таблица 1.3 — Современные методы оптимизации CNN

Метод	Суть метода	Практическое значение
Pruning	Удаление малозначимых весов/каналов обученной сети	Сокращение размера и вычислительных затрат готовой модели
Quantization	Снижение разрядности весов и активаций	Ускорение вычислений и экономия памяти на целевом устройстве

Метод	Суть метода	Практическое значение
Knowledge distillation	Обучение компактной модели на «мягких» предсказаниях крупной модели	Повышение точности компактных моделей для развёртывания на слабом оборудовании
Transfer learning	Дообучение предобученной модели на данных целевой задачи	Снижение требований к объёму размеченных данных целевой задачи

1.4 Выводы и рекомендации

Развитие архитектур CNN прошло путь от простых неглубоких сетей (LeNet) через архитектуры, максимизирующие точность за счёт глубины (AlexNet, VGG, GoogLeNet, ResNet, DenseNet), к архитектурам, оптимизированным по соотношению точности и вычислительных затрат (MobileNet, EfficientNet) [1] за счёт остаточных связей, плотных связей, разделяемой по глубине свёртки и согласованного масштабирования.

К преимуществам CNN относится автоматическое извлечение иерархии признаков без ручного конструирования, обеспечившее успех от классификации изображений до медицинской диагностики и промконтроля качества [1, 3, 4] к ограничениям — объём требуемых данных, вычислительные затраты, недостаточная интерпретируемость и чувствительность к смещению распределения данных при переносе в эксплуатацию [3].

Наиболее перспективны архитектуры и методы, повышающие эффективность, а не только точность: EfficientNet, MobileNet, pruning, quantization, knowledge distillation и transfer learning [1, 12]. Применение CNN наиболее оправдано в задачах с выраженной пространственной структурой данных при достаточном объёме обучающих данных — прежде всего в классификации, сегментации и медицинской визуализации [1, 3] ограничением остаются задачи с малым объёмом данных и высокой ценой ошибки, где требуется дополнительный контроль качества и, как правило, перенос обучения [3].

Практические рекомендации по выбору архитектуры CNN:

1. При большом размеченном наборе данных и отсутствии жёстких ограничений на вычисления — глубокие архитектуры на основе

остаточных или плотных связей (ResNet, DenseNet) либо старшие конфигурации EfficientNet.

2. При развёртывании на мобильном или встраиваемом устройстве с ограничениями по памяти и энергопотреблению — MobileNet или младшие конфигурации EfficientNet, при необходимости в сочетании с прореживанием и квантованием.
3. При ограниченном объёме данных целевой задачи (медицинская визуализация, нестандартная продукция) — перенос обучения с предобученных на крупных датасетах моделей вместо обучения «с нуля».
4. Для задач, требующих одновременно высокой точности и экономичности на конечном устройстве, — дистилляция знаний.
5. Для задач с высокой ценой ошибки и требованием обоснования решения — дополнительная оценка устойчивости модели и методы повышения интерпретируемости.

ЗАКЛЮЧЕНИЕ

В ходе выполнения данного этапа учебной (аналитической) практики был проведён анализ профессиональной информации по индивидуальной теме «Анализ сверточных нейронных сетей и областей их практического применения».

Были решены все поставленные задачи исследования: раскрыт принцип работы сверточных нейронных сетей; систематизированы восемь основных архитектур CNN (LeNet, AlexNet, VGG, GoogLeNet/Inception, ResNet, DenseNet, MobileNet, EfficientNet) с их сравнением по единым критериям; рассмотрены двенадцать областей практического применения CNN с указанием задач, архитектур, преимуществ и ограничений; проведён сравнительный анализ областей применения и современных тенденций развития технологии (лёгкие архитектуры, edge AI, pruning, quantization, knowledge distillation, transfer learning).

По результатам сформулированы выводы о преимуществах и ограничениях CNN, выделены наиболее перспективные архитектуры и методы (EfficientNet, MobileNet, pruning, quantization, knowledge distillation, transfer learning), а также практические рекомендации по выбору архитектуры в зависимости от объёма доступных данных, вычислительных ограничений и цены ошибки решаемой задачи.

Работа над практической частью задания, связанной с операционными системами, будет представлена на следующем этапе.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Alzubaidi L., Zhang J., Humaidi A.J., Al-Dujaili A., Duan Y., Al-Shamma O., Santamaría J., Fadhel M.A., Al-Amidie M., Farhan L. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions // *Journal of Big Data*. — 2021. — Vol. 8, No. 53. DOI: 10.1186/s40537-021-00444-8.
2. LeCun Y., Bottou L., Bengio Y., Haffner P. Gradient-based learning applied to document recognition // *Proceedings of the IEEE*. — 1998. — Vol. 86, No. 11. — P. 2278–2324. DOI: 10.1109/5.726791.
3. Mienye I.D., Swart T.G., Obaido G., Jordan M., Ilono P. Deep Convolutional Neural Networks in Medical Image Analysis: A Review // *Information*. — 2025. — Vol. 16, No. 3, Art. 195. DOI: 10.3390/info16030195.
4. Деркачев В.А., Бахчевников В.В., Бакуменко А.Н. Классификатор изображений семян сельскохозяйственных культур с использованием сверточной нейронной сети // *Известия ЮФУ. Технические науки*. — 2020. — № 4. — С. 32–39. DOI: 10.18522/2311-3103-2020-4-32-39.
5. Krizhevsky A., Sutskever I., Hinton G.E. ImageNet classification with deep convolutional neural networks // *Communications of the ACM*. — 2017. — Vol. 60, No. 6. — P. 84–90. DOI: 10.1145/3065386.
6. Simonyan K., Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition // *International Conference on Learning Representations (ICLR)*. — 2015. — arXiv:1409.1556.
7. Szegedy C., Liu W., Jia Y., Sermanet P., Reed S., Anguelov D., Erhan D., Vanhoucke V., Rabinovich A. Going Deeper with Convolutions // *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. — 2015. — P. 1–9. DOI: 10.1109/CVPR.2015.7298594.
8. He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition // *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. — 2016. — P. 770–778. DOI: 10.1109/CVPR.2016.90.
9. Huang G., Liu Z., Van Der Maaten L., Weinberger K.Q. Densely Connected Convolutional Networks // *Proceedings of the IEEE Conference on Computer*

- Vision and Pattern Recognition (CVPR). — 2017. — P. 2261–2269. DOI: 10.1109/CVPR.2017.243.
10. Howard A.G., Zhu M., Chen B., Kalenichenko D., Wang W., Weyand T., Andreetto M., Adam H. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. — 2017. — arXiv:1704.04861.
 11. Tan M., Le Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks // Proceedings of the 36th International Conference on Machine Learning (ICML). — 2019. — arXiv:1905.11946.
 12. Ладанова Е. О. Проектирование вычислительных комплексов: учебное пособие / Е. О. Ладанова, С. М. Коваленко. — М.: РТУ МИРЭА, 2024. — Текст: электронный // ЭБС МИРЭА. — URL: <https://ibc.mirea.ru/books/SHARE/5902/> (дата обращения: 08.09.2026).